

多臂老虎机问题

先讲一个故事

你走进一家赌场，面前有 K 台老虎机。每台老虎机有自己的中奖概率，但你完全不知道。你有 T 次机会（每次一块钱），想最大化总奖金。

核心困境：把硬币投给哪台机器？

- 投给「看上去不错的」——可能被前几次运气误导，永远错过真正的大奖机器；
- 每台都试一遍——试差的机器纯属浪费。

这就是**探索 (Exploration) vs. 利用 (Exploitation)** 的权衡，强化学习一切问题的源头。

数学形式化

K -臂伯努利老虎机由以下要素定义：

$$\text{Bandit}_K = \{\mu_1, \mu_2, \dots, \mu_K\}, \quad \mu_k \in [0, 1]$$

- μ_k ——第 k 个臂的真实中奖概率（未知）；
- 动作 $a_t \in \{1, \dots, K\}$ ——第 t 步选择哪个臂；
- 奖励 $r_t \in \{0, 1\}$ ——拉完之后实际中的奖， $r_t \sim \text{Bernoulli}(\mu_{a_t})$ ；
- 最优臂 $\mu^* = \max_k \mu_k$ ，对应的臂编号 $k^* = \arg \max_k \mu_k$ 。

目标：在 T 步内选动作序列 $(a_1, \dots, a_T)$ ，最大化期望累积奖励 $\mathbb{E} \left[\sum_{t=1}^T r_t \right]$ 。

懊悔——衡量算法好坏的标尺

定义

最大化奖励等价于最小化**懊悔 (Regret)** ——你因为不知道哪个臂最好而损失了多少。

设第 t 步选了臂 a_t ，该步的**即时懊悔**为：

$$\rho_t = \mu^* - \mu_{a_t}$$

T 步后的**累积懊悔**：

$$R(T) = \sum_{t=1}^T \rho_t = T\mu^* - \sum_{t=1}^T \mu_{a_t}$$

懊悔告诉我们什么

懊悔增长速率	含义
$R(T) = O(T)$ (线性)	算法没在学——每步都在犯错
$R(T) = O(\log T)$ (对数)	算法在学习——犯错越来越少
$R(T) = O(\sqrt{T})$ (平方根)	介于两者之间

Lai & Robbins 下界 (1985): 任何算法至少 $\Omega(\log T)$ ，不可能比对数增长更快。达到 $O(\log T)$ 就是渐近最优的。

贪心策略与 ε -贪心

纯贪心策略 (Greedy)

最朴素的想法：选当前估计最好的臂。

$$a_t = \arg \max_k \hat{\mu}_k(t), \quad \hat{\mu}_k(t) = \frac{\text{臂 } k \text{ 历史上获得的总奖励}}{\text{臂 } k \text{ 被选中的总次数}}$$

致命缺陷：第一次某个次优臂碰巧给了一个 $r = 1$ ，被高估为 $\hat{\mu}_k = 1.0$ 。纯贪心永远不会再碰其他臂，永远卡在次优解。懊悔线性增长。

ε -贪心

核心思想：大部分时间贪心（利用），小部分时间随机探索。

$$a_t = \begin{cases} \text{随机选 } k \in \{1, \dots, K\}, & \text{以概率 } \varepsilon (\text{探索}), \\ \arg \max_k \hat{\mu}_k(t), & \text{以概率 } 1 - \varepsilon (\text{利用}). \end{cases}$$

增量式均值更新 (重要!)

不需要存所有历史奖励。设已有 N 次观测，均值为 $\hat{\mu}_N$ ，新观测 r_{N+1} 到来时：

$$\begin{aligned} \hat{\mu}_{N+1} &= \frac{1}{N+1} \sum_{i=1}^{N+1} r_i = \frac{1}{N+1} \left(r_{N+1} + \sum_{i=1}^N r_i \right) \\ &= \frac{1}{N+1} (r_{N+1} + N\hat{\mu}_N) \\ &= \frac{1}{N+1} (r_{N+1} + (N+1)\hat{\mu}_N - \hat{\mu}_N) \\ &= \hat{\mu}_N + \frac{1}{N+1} (r_{N+1} - \hat{\mu}_N). \end{aligned}$$

$$\hat{\mu}^{\text{new}} = \hat{\mu}^{\text{old}} + \frac{1}{N+1} (r - \hat{\mu}^{\text{old}})$$

为什么这个格式重要？它是整个 RL 更新规则的雏形：

$$\theta \leftarrow \theta + \alpha (\text{Target} - \theta)$$

后面 Q-Learning 的 $Q(s, a) \leftarrow Q(s, a) + \alpha (r + \gamma \max Q - Q(s, a))$ 就是同一个结构。

常值 ε 的遗憾分析

固定 $\varepsilon > 0$ ，每一步以概率 ε/K 选中任一特定臂。次优臂 k 在 T 步中期望被探索 $\frac{\varepsilon}{K}T$ 次，每次产生懊悔 $\Delta_k = \mu^* - \mu_k$ 。

$$\mathbb{E}[R(T)] \geq \sum_{k: \Delta_k > 0} \frac{\varepsilon}{K} T \cdot \Delta_k = \frac{\varepsilon}{K} T \sum_k \Delta_k = \Omega(T)$$

结论：常值 ε 导致线性遗憾——即使 $T \rightarrow \infty$ ，仍有 ε 概率探索，一直浪费。

衰减 ε -贪心

改进：让探索概率随时间衰减。 $\varepsilon_t = 1/t$ ：

$$\mathbb{P}(\text{第 } t \text{ 步探索}) = \frac{1}{t} \rightarrow 0 \quad (t \rightarrow \infty)$$

早期大量探索 (t 小时 ε_t 大)，后期专注利用。遗憾上界降至 $O(\log T)$ ，匹配下界。

乐观初始化

另一个诱导探索的技巧：初始估值全部设为 1.0（最高可能值）。所有臂都被高估——拉一次后某臂估计下降，别的臂依然「虚高」，迫使算法轮流尝试所有臂。天然完成一轮探索后自动收敛到贪心。

上置信界算法 (UCB)

ε -贪心的问题

它的探索是**无方向**的——对所有臂一视同仁随机选，浪费大量机会在明显差的臂上。好的探索应该有方向：「我不确定这个臂好不好，所以试试它」。

核心思想：面对不确定性的乐观主义

UCB 不只看点估计 $\hat{\mu}_k$ ，而是计算一个**置信上界**。不确定性越大的臂，上界被推得越高——即使它的点估计一般，也可能因为「万一好的」而被选中。

$$a_t = \arg \max_k [\hat{\mu}_k(t) + \text{不确定性奖励}]$$

Hoeffding 不等式——如何量化「不确定」

设 $X_1, \dots, X_n$ 为 $[0, 1]$ 内独立同分布随机变量， $\bar{X}_n = \frac{1}{n} \sum_i X_i$ ， $\mu = \mathbb{E}[X_i]$ 。

$$\mathbb{P}(|\bar{X}_n - \mu| \geq \delta) \leq 2 \exp(-2n\delta^2)$$

翻译成成人话： n 次观测后，样本均值偏离真实期望 $\geq \delta$ 的概率以指数级缩小。

将这个不等式反过来用：给定置信度 p ，解 $\exp(-2n\delta^2) = p$ 得到：

$$\delta = \sqrt{\frac{\log(1/p)}{2n}}$$

取 $p = 1/t$ （随时间固定提高置信度），以概率 $\geq 1 - 2/t$ ：

$$\mu_k \in \left[\hat{\mu}_k - \sqrt{\frac{\log t}{2N_k}}, \hat{\mu}_k + \sqrt{\frac{\log t}{2N_k}} \right]$$

选**上界**（乐观估计）：

$$a_t = \arg \max_k \left[\underbrace{\hat{\mu}_k(t)}_{\text{利用}} + c \cdot \underbrace{\sqrt{\frac{\log t}{2N_k(t)}}}_{\text{探索奖励}} \right]$$

直觉:

- 臂被拉得多 (N_k 大) $\rightarrow$ 探索项小 $\rightarrow$ 上界收紧;
- 臂被遗忘 (N_k 小) $\rightarrow$ 探索项大 $\rightarrow$ 上界膨胀 $\rightarrow$ 被重新选中;
- $\log t$ 随 T 极慢增长, 保证长期来看探索代价很小。

c 是控制探索/利用权衡的超参数。实际实现中常对 N_k 加一平滑 ($N_k + 1$), 防止除零并使未拉过的臂具有最大不确定性, 保证所有臂至少被尝试一次。

遗憾上界 (Auer et al. 2002)

UCB1 ($c = 1$) 的理论保证:

$$\mathbb{E}[R(T)] \leq 8 \sum_{k: \mu_k < \mu^*} \frac{\log T}{\Delta_k} + C, \quad \text{即 } O(\log T)$$

达到渐近最优。每个次优臂期望被拉 $\approx \frac{\log T}{\Delta_k^2}$ 次后, 其置信区间窄到不可能再竞争, 之后几乎遗忘。

汤普森采样 (Thompson Sampling)

频率学派 vs. 贝叶斯学派

前三个算法 (Greedy, ϵ -Greedy, UCB) 都是**频率学派**思路: 根据历史数据算出一个点估计 $\hat{\mu}_k$, 再围绕点估计加一些东西 (噪音 / 置信界)。

汤普森采样是**贝叶斯学派**方法: 不维护「一个数」, 而是维护 μ_k 的**完整概率分布**, 表达「我对 μ_k 的信念是什么」。

Beta 分布与共轭先验

伯努利试验的似然函数 (观测到 s 次成功、 f 次失败):

$$P(\text{data} \mid \mu) = \mu^s (1 - \mu)^f$$

Beta 分布的密度函数:

$$\text{Beta}(\theta \mid \alpha, \beta) \propto \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad \theta \in [0, 1]$$

两者有相同的函数形式 (μ 的幂乘 $(1 - \mu)$ 的幂)。这意味着:

如果先验是 Beta 分布, 看到 Bernoulli 数据后, 后验还是 Beta 分布 (共轭性):

$$P(\mu \mid s \text{ 次成功, } f \text{ 次失败}) = \text{Beta}(\alpha_0 + s, \beta_0 + f)$$

取 $\alpha_0 = \beta_0 = 1$, $\text{Beta}(1, 1) = \text{Uniform}(0, 1)$, 即「我一无所知」。

从先验到后验的推导

$$\begin{aligned}P(\mu \mid r_{1:n}) &\propto P(r_{1:n} \mid \mu) \cdot P(\mu) \\&\propto \mu^{\sum r_i} (1 - \mu)^{n - \sum r_i} \cdot \mu^{\alpha_0 - 1} (1 - \mu)^{\beta_0 - 1} \\&= \mu^{\alpha_0 + \sum r_i - 1} (1 - \mu)^{\beta_0 + n - \sum r_i - 1} \\&\propto \text{Beta} \left(\alpha_0 + \sum r_i, \beta_0 + n - \sum r_i \right).\end{aligned}$$

Beta 分布随观测增多而变化：

参数	含义	分布形状
$\alpha = 1, \beta = 1$	无信息先验	均匀分布 $U[0, 1]$
$\alpha = 10, \beta = 10$	9胜9负	集中在0.5 附近，较宽
$\alpha = 80, \beta = 20$	79胜19负	集中在0.8 附近，较窄
$\alpha = 200, \beta = 50$	199胜49负	集中在0.8 附近，更窄（很确定）

数据越多，分布越窄——你对 μ_k 的信念越确定。

算法流程：三行搞定

1. 采样：从每个臂的后验各采一个 $\tilde{\mu}_k \sim \text{Beta}(\alpha_k, \beta_k)$ ；
2. 选： $a_t = \arg \max_k \tilde{\mu}_k$ （贪心选采样值最大的）；
3. 更新： $\alpha_{a_t} \leftarrow \alpha_{a_t} + r_t, \beta_{a_t} \leftarrow \beta_{a_t} + (1 - r_t)$ 。

为什么「从后验采样再贪心」是对的？

概率匹配 (Probability Matching)：选择臂 k 的概率，恰好等于「臂 k 是最优臂」的后验概率。

$$\mathbb{P}(a_t = k) = \mathbb{P}(\mu_k = \max_j \mu_j \mid \text{data})$$

自动平衡探索与利用：

- 不确定性大的臂（Beta 分布宽）→ 采样值波动大，有时很高 → 自然获得探索机会；
- 确定的差臂（Beta 分布窄集中在低值）→ 几乎永远不会被采样超过好臂 → 浪费很少。

遗憾分析 (Agrawal & Goyal 2012)

汤普森采样的期望累积遗憾也达到 $O(\log T)$ ，且常数项匹配 Lai & Robbins 下界——它是**常数最优**的。在实践中通常表现最好。

四种算法对比总结

探索方式的核心差异

- ϵ -Greedy：无差别随机探索。「规则让我随机试，我就随机试。」

- **UCB**: 有方向探索。「我不确定 B 臂, 万一它很好呢? 给它一个机会。」
- **Thompson Sampling**: 概率化探索。「我的信念是 B 臂有 30% 概率最好, 那么我有 30% 的概率选它。」
- **Decaying ϵ -Greedy**: 和 ϵ -Greedy 同类, 但探索概率衰减。

一表打尽

算法	探索方式	理论遗憾	特点
ϵ -Greedy	随机均匀	$O(T)$ (线性)	最简单, 但遗憾不收敛
Decaying- ϵ	随机均匀, 概率衰减	$O(\log T)$	简单改进
UCB	有方向 (置信界)	$O(\log T)$	确定性, 调参简单
Thompson Sampling	有方向 (后验采样)	$O(\log T)$ 最优常数	实践中最强

实际选择建议

1. 快速原型 / 教学: ϵ -Greedy 或 Decaying ϵ -Greedy。
2. 需要理论保证 + 调参少: UCB (仅 c 一个参数)。
3. 实际应用 (推荐系统、广告投放、A/B 测试): **Thompson Sampling**, 通常表现最好, 且能自然融入领域知识作先验。

本章在 RL 体系中的位置

MAB 是单状态的强化学习。理解了本章, 你就握住了 RL 三个核心概念的种子:

1. **探索 vs. 利用**——MAB 是最纯粹的形式; MDP 中变成「探索哪个状态-动作对」, 同构问题。
2. **增量更新** $\theta \leftarrow \theta + \alpha(\text{Target} - \theta)$ ——这是 TD 学习、Q-Learning、Policy Gradient 的统一更新骨架。
3. **不确定性驱动的探索**——UCB $\rightarrow$ count-based exploration $\rightarrow$ RND (Random Network Distillation), 一路演化; Thompson Sampling $\rightarrow$ PSRL (Posterior Sampling RL), 是 Bayesian RL 的起点。

下一章 MDP 把「单状态」扩展为「状态转移」, 加上 Markov 性质和 Bellman 方程, 整个 RL 的理论大厦就立起来了。

参考资料

1. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 2.
2. Lai & Robbins (1985). Asymptotically efficient adaptive allocation rules. *Advances in Applied Mathematics*.
3. Auer, Cesa-Bianchi & Fischer (2002). Finite-time analysis of the multiarmed bandit problem. *Machine Learning*.

4. Agrawal & Goyal (2012). Analysis of Thompson sampling for the multi-armed bandit problem. *COLT*.
5. 动手学强化学习 (Hands-on-RL) . 第 2 章: 多臂老虎机.