

n 步回报

先讲一个故事

你已经知道了 DQN 和 A2C/PPO。回头看它们的更新目标：

$$\underbrace{r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a')}_{\text{DQN 的目标 (1 步 bootstrap)}} \qquad \underbrace{\sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}}_{\text{REINFORCE 的目标 (完整 MC 回报)}}$$

两个极端。A2C 引入 GAE, PPO 默认 $\lambda = 0.95$ ——它们都在做同一件事：在「只看一步」和「看完整条轨迹」之间找一个折中点。

这个折中点的名字，就是 n 步回报。

它是 DQN、A2C、PPO 共同的地基，在我们写出那些算法之前就应该先讲清楚的东西。今天倒回来把这块砖补上。

数学形式化

从状态 s_t 出发，沿真实轨迹走 n 步，再用价值函数对 s_{t+n} 做 bootstrap：

$$G_t^{(n)} = \sum_{k=0}^{n-1} \gamma^k r_{t+k+1} + \gamma^n V(s_{t+n})$$

- 前半段 $\sum \gamma^k r_{t+k+1}$ ： n 步真实奖励，无偏但带随机性；
- 后半段 $\gamma^n V(s_{t+n})$ ：从第 n 步起的估计价值，快速但依赖网络精度；
- $n = 1$ 退化为 TD(0) (DQN 的目标)； $n \rightarrow \infty$ 退化为 MC 回报 (REINFORCE 的目标)。

偏差与方差：两步之间的取舍

bootstrap 带来的偏差

$G_t^{(1)}$ 把未来的所有不确定性「外包」给了 $V(s_{t+1})$ ：

$$G_t^{(1)} = r_{t+1} + \gamma \cdot \underbrace{V(s_{t+1})}_{\text{训练初期精度有限}}$$

如果 V 尚未收敛，bootstrap 值会把网络当前的估计误差直接拉进训练目标。 $n = 1$ 对 V 的精度最敏感——它把所有未来折扣奖励全部交给 V 来代理。

多走 n 步之后，bootstrap 的影响被 γ^n 压缩：

$$\text{偏差} \propto \gamma^n \cdot \|V_\theta(s_{t+n}) - V^*(s_{t+n})\| \xrightarrow{n \uparrow} 0$$

$\gamma = 0.99$, $n = 16$: $\gamma^{16} \approx 0.85$, bootstrap 的影响已缩减近 15%。如果实验中 episode 较短，甚至不需要考虑 bootstrap 的缩减影响， $n = 16$ 往往直接退化为 MC 而无需 bootstrap。

注意：这并不意味着 $n = 1$ 不能收敛。DQN 正是用 $n = 1$ 的 TD(0) 目标，配合高频 target 网络同步（每 100 步一次）和大容量 replay buffer，将 bootstrap 偏差控制在可接受范围内——工程设施弥补了理论上的敏感性。

Monte Carlo 带来的方差

$G_t^{(\infty)}$ 完全依赖真实奖励，bootstrap 权重为零，偏差为零。但 $T - t$ 个随机变量叠加：

$$\text{Var}[G_t^{(\infty)}] = \sum_{k=0}^{T-t-1} \gamma^{2k} \cdot \text{Var}[r_{t+k+1}]$$

轨迹越长，方差越大，梯度信号越嘈杂。

实验验证：从同一起点出发的 400 条轨迹




图 1: 从固定初始状态出发, ϵ -greedy ($\epsilon = 0.25$) 采集 400 条轨迹, 计算各 n 步回报估计 $G_0^{(n)}$ 的分布。Bootstrap 使用仅训练 100 episode 的参考网络 (体现早期偏差)。左: 分布形态, 方差随 n 递增清晰可见; 右: 均值 $\pm 1\sigma$, $n=1$ 均值 (3.06) 远低于 MC (11.83), 偏差显著。

n	均值	标准差 (σ)	解读
1	3.06	0.10	强偏向网络估计, 极低方差, 高偏差
4	6.26	0.19	偏差减半, 方差仍低
16	11.80	1.69	接近真实价值, 方差升高
MC	11.83	1.83	无偏, 但方差最大

$n=1$ 的均值 (3.06) 远低于 MC (11.83), 正是因为参考网络在早期把价值严重低估, bootstrap 把这个错误拉进了估计里。 $n=16$ 和 MC 均值几乎一致, 说明偏差已经消除。

n 步回报对训练动态的影响

学习曲线: $n=1$ 卡死, $n=16$ 收敛

$n=1$ 在本实验中卡死的机制:

- 实验中 target 网络每 20 个 episode 才同步一次 (而非 DQN 的每 100 步), 早期 $G_t^{(1)} = r + \gamma V_\theta(s')$ 长期使用不准确的 bootstrap;
- 这些偏差目标积压在 replay buffer, 混入后续所有 mini-batch;




图 2: CartPole-v1, 各 n 步 Q-learning 学习曲线 (5 个随机种子, $\pm 1\sigma$ 阴影, 平滑窗口 = 20)。n=1 全部种子卡死在 ≈ 9.9 (随机水平); n=4 部分种子学习; n=16 和 MC 均收敛至 200 以上。

3. Q 网络被拉向错误方向, target 网络同步后继承偏差, 循环难以自我纠正。

这是实验设定放大了 $n=1$ 的敏感性, 而非 $n=1$ 本身不可行。DQN 用更密集的 target 同步策略解决了同一问题。

$n=16$ 在本实验中幸免于难: 早期 episode 平均只有约 9 步, $n = 16 > T$, 实际退化为完整 MC 回报, 无需 bootstrap, 因此对 target 网络精度完全免疫。

翻译成成人话: 靠自己多走几步, 就不那么需要依赖一个还没学好的老师给的答案。

CartPole 之外: 更长 episode 里的甜点

CartPole 的 episode 很短 (约 9 步), 任意 $n \geq 9$ 都退化为 MC, 因此 Fig 1 只能看出「 $n=1$ vs 其余」的二分。在 episode 长达数千步的环境里 (可以去看一看 Rainbow 那篇论文), 偏差-方差的折中才真正显现: $n = 3$ 时 bootstrap 权重 $\gamma^3 \approx 0.97$, bootstrap 依赖已有所压缩, 而方差远小于完整 MC 回报——这是在更长 episode 任务上实践验证的折中点。

TD(λ): 把 n 软化成连续参数

前向视角: 对所有 n 步回报做加权平均

不固定单一的 n , 而是用 $\lambda \in [0, 1]$ 对所有 n 步回报做指数加权平均:

$$G_t^\lambda = (1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} G_t^{(n)}$$

权重 $(1 - \lambda)\lambda^{n-1}$ 以 λ 为公比递减, 短步权重高。 $(1 - \lambda) \sum_{n=1}^{\infty} \lambda^{n-1} = 1$, 权重归一。

后向递推：代码里真正用的形式

前向视角需要知道整条未来轨迹，无法在线高效计算。等价的后向递推从轨迹末尾反向扫描一遍即可：

$$G_t^\lambda = r_{t+1} + \gamma[(1 - \lambda)V(s_{t+1}) + \lambda G_{t+1}^\lambda]$$

边界条件： $G_T^\lambda = r_T$ （终止状态无后继，无需 bootstrap）。

验证两极端：

- $\lambda = 0$: $G_t^0 = r_{t+1} + \gamma V(s_{t+1})$, 纯 TD(0) 目标 ✓
- $\lambda = 1$: $G_t^1 = r_{t+1} + \gamma G_{t+1}^1$, 标准 MC 回报递推 ✓

TD(λ) 实验结果




图 3: CartPole-v1, 四种 λ 值的 TD(λ) Q-learning (5 个种子, $\pm 1\sigma$, 平滑窗口 = 20)。 $\lambda = 0$ 与 $\lambda = 1$ 行为完全一致，全部卡死； $\lambda = 1.0$ 即 MC 表现最优。

λ	含义	last-50 平均回报
0.0	纯 TD(0), 完全依赖 bootstrap	≈ 9.6 (卡死)
0.5	中等权重, 仍高度依赖 bootstrap	11 ~ 41(不稳定)
0.9	偏重长步, bootstrap 依赖少	158 ~ 324(收敛)
1.0	纯 MC, 完全不用 bootstrap	298 ~ 415(最优)

结论与 Fig 1 一致： λ 越高，对 bootstrap 依赖越少，早期训练越稳定。

与 GAE 的关系

A2C 和 PPO 里的 **GAE** (广义优势估计) 是 TD(λ) 在优势函数上的直接应用。

定义 TD 误差 $\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$, 则:

$$A_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{T-t-1} (\gamma\lambda)^l \delta_{t+l}$$

翻译成成人话: GAE 把一串 TD 误差用 $\gamma\lambda$ 指数衰减地加起来。 $\lambda = 1$ 把所有步全加完 ($\approx$ MC 优势); $\lambda = 0$ 只用当步误差 ($=$ 1 步 TD 优势)。

PPO 默认 $\lambda = 0.95$ 的含义: 网络已具备一定精度, 此时适度降低 MC 依赖 (略小于 1) 可以压缩方差, 加速后期收敛。

四种估计方式的横向对比

方法	公式	偏差	方差	典型应用
TD(0)	$r + \gamma V(s')$	高 (依赖 V)	低	DQN ($n=1$)
n -step	$\sum_{k < n} \gamma^k r_{k+1} + \gamma^n V$	中	中	实践中常用 $n=3 \sim 10$
MC	$\sum_k \gamma^k r_{k+1}$	零	高	REINFORCE
TD(λ)	$(1 - \lambda) \sum_n \lambda^{n-1} G^{(n)}$	可调	可调	GAE in PPO ($\lambda=0.95$)

为什么实践中偏向大 n 或大 λ ?

1. **早期训练:** V 还不准, bootstrap 危险。大 n / 大 λ 减少对 V 的依赖, 学习更稳定——这是本章实验的核心发现。
2. **后期训练:** V 已经较准, MC 的高方差反而拖慢收敛。适度减小 n 或 λ 降低方差——PPO 用 $\lambda = 0.95$ 而非 1.0, 即出于此考量。
3. **折中的本质:** 并无理论最优, 中等 n 和 $\lambda = 0.95$ 均为实践中多任务验证的稳健值。

本章在 RL 体系中的位置

n 步回报是一块被后来算法反复引用、却没有被单独讲清楚的地基:

1. **TD 路线** $\rightarrow$ TD(0) $\rightarrow$ n -step TD $\rightarrow$ DQN ($n = 1$): 这条线一路都是 bootstrap, 区别在于用多少步真实奖励来稀释 bootstrap 的影响, 以及用什么工程手段 (target 网络、replay buffer) 控制偏差。
2. **MC 路线** $\rightarrow$ REINFORCE $\rightarrow$ Actor-Critic: MC 回报 ($n = \infty$) 是 REINFORCE 的基础, 消除方差是从 MC 到 AC 的核心动机。
3. **λ 路线** $\rightarrow$ TD(λ) $\rightarrow$ GAE $\rightarrow$ PPO/A2C: λ 把离散的 n 连续化, GAE 把它用在优势函数上, PPO/A2C 默认 $\lambda = 0.95$ 。

一个值得思考的问题: DQN 选了 $n = 1$, 而非 MC——为什么在 episode 足够长的环境里, MC 回报反而不是更好的选择?

参考资料

1. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 7: n -step Bootstrapping.
2. Mnih et al. (2015). Human-level control through deep reinforcement learning. *Nature*. (DQN 原论文, $n = 1$)
3. Schulman et al. (2016). High-dimensional continuous control using generalized advantage estimation. *ICLR*. (GAE 原论文, TD(λ) 的优势函数版本)
4. Mnih et al. (2016). Asynchronous methods for deep reinforcement learning. *ICML*. (A3C, n -step target 的实践应用)