

PPO (Proximal Policy Optimization)

先讲一个故事

你是一名武术选手，每次上场（一次 rollout）结束后，教练（优势函数 $\hat{A}$ ）给你一份详细的复盘报告：「第 23 秒的侧踢应该更快」、「第 47 秒的防守太保守了」。报告基于你当时的打法（旧策略 $\pi_{\theta_{\text{old}}}$ ）写成。

你拿到报告，朝最优方向调整一遍。感觉还不够，再调整一遍……调了 $K = 20$ 遍之后，你已经变成了一个截然不同的选手——可教练的建议还是当初那份，基于二十轮前的你写的。你越按报告调，动作越奇怪，最终反而一败涂地。

核心矛盾：

- 数据是旧策略 $\pi_{\theta_{\text{old}}}$ 收集的；
- 每轮更新的目标是新策略 π_{θ} ；
- 更新越多，两者越远——数据越失效。

这就是无约束多轮策略更新的困境，也是 PPO 要解决的核心问题：

如何在浪费样本的前提下，安全地多次更新策略？

数学形式化

策略梯度定理给出参数梯度方向：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[\nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \hat{A}_t \right]$$

为了重复使用旧策略收集的数据，引入**重要性采样权重**（策略比值）：

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}$$

$r_t = 1$ 表示新旧策略在该步完全一致； $r_t \gg 1$ 或 $r_t \ll 1$ 表示策略已经严重偏离。

代入代理目标（Surrogate Objective）：

$$L^{\text{CPI}}(\theta) = \mathbb{E}_t \left[r_t(\theta) \hat{A}_t \right]$$

翻译成成人话：把每步的优势 $\hat{A}_t$ 乘以「新旧策略的比值」，多次优化这个代理目标就能多次复用同一批数据。**问题是：** K 轮更新后 r_t 可能偏离 1 很远，代理目标变得不可信，梯度方向失效。

无约束更新为什么会崩溃？

重要性采样的有效范围

重要性采样的隐含前提是两个分布「足够相近」。若 π_{θ} 与 $\pi_{\theta_{\text{old}}}$ 差距过大，估计方差爆炸：

$$\text{Var} \left[r_t(\theta) \hat{A}_t \right] \propto \mathbb{E} [r_t^2(\theta)] - 1$$

当 r_t 偏离 1（无论偏大还是偏小），梯度估计的方差急剧增大，更新方向变得不可靠。

K 轮更新导致 r 漂移

以无 clip 的 PPO ($K = 20$ 轮) 为例, 每轮更新后 θ 改变, $r_t(\theta)$ 随之漂移:

- 第 1 轮: $r_t \approx 1$, 梯度估计可信;
- 第 4 轮: r_t 开始偏离, 优势估计出现偏差;
- 第 8 轮: r_t 严重偏离, 优势估计彻底失效, 梯度方向错误, 训练崩溃。




图 1: 无 clip 的 PPO ($K = 20$ 轮, mini-batch) 在 LunarLander-v3 上的 5 个 seed (蓝色细线)。部分 seed 在早期回报跌至 -8000 (随机策略的 40 倍更差), 随后缓慢恢复。平滑均值 (红色) 在整个训练期间始终低于有 clip 的版本。

PPO-Clip: 截断代理目标

核心公式

PPO 的解决方案极其简洁: 把 r_t 截断到 $[1 - \varepsilon, 1 + \varepsilon]$ 附近, 超出部分不再提供梯度激励。

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right]$$

ε 通常取 0.2。

直觉：剪掉两种极端

分两种情况理解 $\min$ 的含义。

情况 A: $\hat{A}_t > 0$ (这步动作比平均水平好，想增大它的概率)

- r_t 增大 (新策略更倾向此动作) $\rightarrow$ 好，但超过 $1 + \varepsilon$ 时取 clip 值，梯度归零；
- **核心原则:** 策略改动「已经够了」，不再继续推动。

情况 B: $\hat{A}_t < 0$ (这步动作比平均水平差，想减小它的概率)

- r_t 减小 (新策略远离此动作) $\rightarrow$ 好，但低于 $1 - \varepsilon$ 时取 clip 值，梯度归零；
- **核心原则:** 同上，过度回避也不再激励。

只有更新朝有利方向走且尚未超限时，才提供梯度驱动。

clip 如何压制 r 的漂移




图 2: PPO-Clip (蓝) vs 无 Clip PPO (红) 在 LunarLander-v3 上 (5 seeds, 均值 $\pm$ 标准差)。横轴为环境交互步数 ($\times 10^3$), 两方法总步数完全相同 ($300 \times 2048 \approx 614k$), 排除了「好策略 episode 更长导致 episode 数更少」的混淆因素。Clip 版本稳定上升, 约 400k 步后进入正回报区间; 无 Clip 版本早期崩至 $-600 \sim -1000$, 缓慢恢复, 始终落后且方差更大。

为什么 clip 起作用?

1. **限制每步更新的「步幅」:** $r_t \in [1 - \varepsilon, 1 + \varepsilon]$ 等价于新旧策略的概率比不超过 $\pm 20\%$;

2. **对称保护**: 既防止某动作概率被过度增大, 也防止被过度减小;
3. **悲观下界**: L^{CLIP} 是 L^{CPI} 的下界, 不会「自欺欺人」地高估提升量——只有真实提升时才更新。




图 3: 每个 epoch 开始前、以全批数据测量的均值策略比值 r_t (5 seeds, 均值 $\pm$ 标准差)。无 Clip (红) 偏离更大, 早期可达 ~ 1.017 ; PPO-Clip (蓝) 始终贴近 1。均值之外, 个别 transition 的 r_t 可远超 1.2 的 clip 边界, 正是这些尾部被 clip 截断, 防止了错误梯度的累积。

广义优势估计 (GAE)

为什么需要 GAE?

优势函数 $A(s, a) = Q(s, a) - V(s)$ 衡量「这步动作比平均水平好多少」。实践中有两种极端估计:

方法	偏差	方差
$\hat{A}^{\text{MC}} = \sum_{l=0}^{\infty} \gamma^l r_{t+l} - V(s_t)$	零偏差	极大
$\hat{A}^{\text{TD}} = r_t + \gamma V(s_{t+1}) - V(s_t)$	有偏	极小

GAE 在两者之间插值, 用 $\lambda \in [0, 1]$ 控制偏差-方差权衡。

GAE 公式

定义 TD 残差（一步时序差分误差）：

$$\delta_t^V = r_t + \gamma V(s_{t+1}) - V(s_t)$$

GAE 对指数加权的多步 TD 残差求和：

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V$$

等价的递推形式（实现中使用，从末尾向前归纳）：

$$\hat{A}_t = \delta_t^V + \gamma \lambda \hat{A}_{t+1}$$

λ 的意义：在 TD 与 MC 之间插值

λ	退化为	效果
$\lambda = 0$	$\hat{A}_t = \delta_t^V$ (1 步 TD)	低方差，有偏差
$\lambda = 1$	$\hat{A}_t = \sum_{l=0}^{\infty} \gamma^l r_{t+l} - V(s_t)$ (MC)	零偏差，高方差
$\lambda = 0.95$	实践中常用	偏差/方差折中

翻译成人话： λ 越大，越相信实际采样的远期回报，而非 critic 的预测。PPO 通常取 $\gamma = 0.99$, $\lambda = 0.95$ 。

PPO 完整算法

总损失函数

$$L^{\text{PPO}}(\theta) = L^{\text{CLIP}}(\theta) - c_1 L^{\text{VF}}(\theta) + c_2 S[\pi_\theta]$$

各项含义：

- L^{CLIP} ：截断策略梯度损失（最大化）；
- $L^{\text{VF}} = \mathbb{E}_t \left[\left(V_\theta(s_t) - \hat{V}_t^{\text{target}} \right)^2 \right]$ ：Critic 的均方误差（最小化， $c_1 \approx 0.5$ ）；
- $S[\pi_\theta] = \mathbb{E}_t \left[-\sum_a \pi_\theta(a|s_t) \log \pi_\theta(a|s_t) \right]$ ：熵奖励，防止策略过早退化（最大化， $c_2 \approx 0.01$ ）。

Actor 和 Critic 共享网络参数 θ ，一次反向传播同时更新两者。

PPO-Clip 算法流程

1. **收集 rollout**：用 $\pi_{\theta_{\text{old}}}$ 在环境中运行 T 步，记录 (s_t, a_t, r_t, s_{t+1}) ；
2. **估计优势**：用 GAE 计算 $\hat{A}_t$ ，令回报目标 $\hat{V}_t^{\text{target}} = \hat{A}_t + V_{\theta_{\text{old}}}(s_t)$ ；
3. **K 轮 mini-batch 更新**：

- (a) 前向传播, 计算 $r_t(\theta)$ 、 $L^{\text{PPO}}(\theta)$;
 - (b) 梯度裁剪 ($\|\nabla\theta\|_2 \leq 0.5$), 反向传播;
 - (c) 更新 θ 。
4. 令 $\theta_{\text{old}} \leftarrow \theta$, 返回第 1 步。

为什么 K 轮更新安全了? clip 把每步的 r_t 限制在 $[1 - \epsilon, 1 + \epsilon]$, 即使 $K = 20$, π_θ 也始终不会脱离 $\pi_{\theta_{\text{old}}}$ 的信任域。

PPO vs 其他策略梯度方法

一表打尽

方法	样本效率	稳定性	实现复杂度
REINFORCE	极低 (每批更新一次)	低 (高方差)	最简单
A2C	低 (同上)	中	简单
TRPO	高 (K 轮更新)	高 (KL 约束)	极复杂 (二阶)
PPO-Clip	高 (K 轮更新)	高 (clip 约束)	简单 (一阶)

为什么 PPO 比 TRPO 更流行?

TRPO (Trust Region Policy Optimization) 用 KL 散度作硬约束:

$$\max_{\theta} L^{\text{CPI}}(\theta) \quad \text{s.t.} \quad \hat{\mathbb{E}}_t[D_{\text{KL}}(\pi_{\theta_{\text{old}}}(\cdot | s_t) \parallel \pi_{\theta}(\cdot | s_t))] \leq \delta$$

理论上最严格, 但需要计算自然梯度 (Fisher 信息矩阵求逆), 在深度网络上成本极高。

PPO 把「信任域」变成**软约束**: 超出部分不是被惩罚, 而是不再提供梯度激励。

- **TRPO**: 「越界了就罚」(硬约束, 二阶优化);
- **PPO**: 「快到边了就不推了」(软约束, 一阶优化)。

效果相当, 但 PPO 仅需一阶梯度, 实现简洁、速度快, 成为在线策略方法的默认基线。

本章在 RL 体系中的位置

1. **TD 路线** $\rightarrow$ Q-Learning $\rightarrow$ DQN (离散动作, 值函数方法);
2. **MC 路线** $\rightarrow$ REINFORCE $\rightarrow$ 策略梯度 (高方差, 每批仅更新一次);
3. **Actor-Critic** $\rightarrow$ GAE $\rightarrow$ PPO (本章: 低方差 + 安全多轮更新);
4. **连续动作 / 离线场景** $\rightarrow$ SAC (最大熵 RL, 离线友好) $\rightarrow$ 离线 RL (IQL 等)。

PPO 是当前在线策略 RL 的默认基线——几乎所有 RLHF (大模型对齐) 都以 PPO 为核心。既然 PPO 已经如此稳健, 为什么还需要为连续动作和离线场景单独设计新算法?

参考资料

1. Schulman et al. (2017). Proximal Policy Optimization Algorithms. *arXiv:1707.06347*.
2. Schulman et al. (2015). Trust Region Policy Optimization. *ICML*.
3. Schulman et al. (2016). High-Dimensional Continuous Control Using Generalized Advantage Estimation. *ICLR*.
4. Sutton & Barto (2018). *Reinforcement Learning: An Introduction* (2nd ed.). Chapter 13.
5. 动手学强化学习 (Hands-on-RL) . 第 12 章: PPO 算法.